Qwen-Audio-3.1-Realtime： 全双工实时语音交互

端到端全双工 · Voice Agent Harness 分层运行时 · 千问语音大模型专场（9/23）

3 层 Harness 架构　**3 类** 落地场景　**5 代** 技术路线

一句话定位： Realtime 不是单个模型，而是「多模型 + 分层运行时」的组合——前台实时语音模型 + 多个后台 Agent 模型（Harness 调度），训练侧再由 4 个专家模型汇聚成 Main AudioLM 。

架构 Architecture

① Voice Agent Harness 三层

L1 实时前台： Qwen Audio Realtime （含 TTS/ASR/Interrupt 子模块，非阻塞交互）
L2 网关协调： Voice Gateway+TaskManager · Backend Agent Adapter · 确定性路由
L3 持久执行：独立 Backend Session + Tools/Workspace （支撑长任务）

② AudioLM 后训练：多专家汇聚（非单模型）

4 个 Domain Experts： 音频理解 / Agentic / 共情 & 角色 / 口语 & 安全
Core-Cocktail SFT 保文本 → Multi-Teacher OPD 汇聚为 Main AudioLM

③ 双工技术路线：级联 → 端到端

规则级联 → LLM 级联 → S2T+CTTS → AudioDuplex+CTTS → Duplex S2S
趋势：显式模块链接 → 文本语义中转 → 语义异构解耦 → 端到端耦合

场景 Scenarios

① 工作助理 · 多步骤执行

表达需求（「会议提前，帮我调整安排」）→ 前台确认（澄清时间 / 对象 / 优先级）
→ 后台执行（查日程 · 整理材料 · 创建任务）→ 结果回流（汇报变化并等待确认）

② 智能座舱 · 多人鲁棒性

持续感知（噪声 · 乘员 · 行驶场景）→ 语义判断（识别指向 · 意图 · 紧急度）
→ 安全执行（导航 · 车控 · 服务调用）→ 适时反馈（简洁播报，减少驾驶干扰）

③ 客户服务 + 角色扮演

客户服务 · 知识与工具结合：双人沟通 → 上下文理解 → 后台核验 → 确认执行
口语角色扮演：口音与智商兼顾，简洁与情商兼顾（共情 Demo ）

效果 Results

① 技术演进 5 代（官方脉络）

Siri （指令入口）→ 小冰（对话对象）→ 小爱 / 天猫精灵（终端入口）
→ GPT-4o Realtime （实时伙伴）→ GPT Live （行动型 Agent ）
螺旋式演进：从设备入口 → 持续在线的协作伙伴

② 能力三维

交互性：低时延 · 准确 · 打断与轮转
情绪价值：共情 · 语气 · 情感 · 口语与角色
Agentic： 工具调用与任务协同（模型直供自然交互，Harness 承载长任务）

③ 评测与开源

官方 Bench 评测：共情 / 人设（雷达对比）
开源 Harness： github.com/Qwenlm/qwen-audio-agent

结论： Realtime 的护城河不在「模型指标」而在「Harness 运行时」——语义双工控制（判断打断 or 附和） + 状态与记忆管理 + 后台任务生命周期，三者共同构成可长期在线的语音 Agent

数据来源： 2026 云栖大会「千问语音大模型」专场官方回放（agendaId=146 ）逐帧提取，内容均取自现场官方 PPT